



UNIVERSITÉ DE MONCTON
EDMUNDSTON MONCTON SHIPPAGAN

Optimisation

MATH 3163



Ibrahima Dione

Hiver 2024

Chapitre 1

Notions fondamentales

Sommaire

1	▪ Définitions	PAGE 2
2	▪ Éléments de topologie et de calcul différentiel	PAGE 4
2.1	- Éléments de topologie	4
2.2	- Éléments de calcul différentiel	7
2.3	- Développement de Taylor et formule de la moyenne	10
3	▪ Rappels sur les matrices définies positives	PAGE 11
4	▪ Ensembles et fonctions convexes	PAGE 13
4.1	- Ensembles convexes	13
4.2	- Fonctions convexes	14

1 Définitions

La structure de la plupart des problèmes de programmation mathématique, est un problème d'optimisation sous contrainte qui peut s'écrire de la façon suivante [2, 1] :

$$(P) \quad \begin{cases} \text{Minimiser } f(x) \\ \text{sous les contraintes :} \\ (i) \quad g_j(x) = 0, \quad j = 1, \dots, m \\ (ii) \quad h_j(x) \leq 0, \quad j = 1, \dots, p \end{cases} \quad (1.1)$$

où

- le vecteur $x = \begin{pmatrix} x_1 \\ x_2 \\ \vdots \\ x_n \end{pmatrix}$ est l'inconnue du problème,
- la fonction f est appelée la **fonction objectif** (appelée parfois **fonction économique**),
- et l'ensemble des conditions en (i) et en (ii) sont appelées les **contraintes** du problème d'optimisation.

Définition 1.1

L'ensemble $S = \{x \in \mathbb{R}^n, g_j(x) = 0, j = 1, \dots, m, \text{ et } h_j(x) \leq 0, j = 1, \dots, p\}$ est appelé **ensemble des points admissibles**.

Définition 1.2

On appelle **solution optimale** ou **optimum global** de (P) , un point admissible x^* (c'est-à-dire $x^* \in S$) tel que

$$f(x^*) \leq f(x), \forall x \in S.$$

Note : Soit le vecteur $x = (x_1, \dots, x_n)^t \in \mathbb{R}^n$.

- La **norme euclidienne** de x notée $\|x\|$ est définie par

$$\|x\| = \sqrt{x_1^2 + x_2^2 + \dots + x_n^2}$$

- On appelle **voisinage** de x , l'ensemble noté $V_\varepsilon(x)$ et défini comme suit

$$V_\varepsilon(x) = \{y \in \mathbb{R}^n \mid \|x - y\| < \varepsilon\}, \text{ pour } \varepsilon > 0.$$

Définition 1.3

- Un vecteur x^* est une **solution locale** ou **optimum local** du problème (P) , s'il existe un voisinage $V_\varepsilon(x^*)$ de x^* tel que x^* soit optimum global du problème

$$\begin{cases} \text{Minimiser } f(x) \\ \text{sous les contraintes :} \\ x \in S \cap V_\varepsilon(x^*) \end{cases} \quad (1.2)$$

- En d'autres termes, $g_i(x^*) = 0, i = 1, \dots, m, h_i(x^*) \leq 0, i = 1, \dots, p$ et

$$\exists \varepsilon > 0, \text{ tel que } f(x) \geq f(x^*) \text{ pour } \begin{cases} x \in V_\varepsilon(x^*) \\ g_i(x) = 0, i = 1, \dots, m \\ h_j(x) \leq 0, i = 1, \dots, p \end{cases} \quad (1.3)$$

La figure suivante illustre, à travers une fonction à une seule variable, les notions de solution globale et de solution locale.




FIGURE 1.1 – Optimum local et optimum global

Nous verrons plus loin qu'il est souvent possible de caractériser les optimums locaux d'un problème, c'est-à-dire de donner des conditions nécessaires et / ou suffisantes pour qu'une solution x soit un optimum local.

Par contre il est généralement impossible de caractériser les optimums globaux d'un problème d'optimisation sauf dans le cas très particulier des fonctions convexes. Ceci explique la difficulté de résolution des programmes mathématiques non convexes.

2 Éléments de topologie et de calcul différentiel

Ce paragraphe est consacré aux rappels de quelques notions fondamentales.

2.1 Éléments de topologie

Nous nous plaçons ici dans \mathbb{R}^n muni de la norme euclidienne $\|\cdot\|$.

- À partir de cette norme, on peut définir la **distance** $d(x, y)$ entre deux éléments $x, y \in \mathbb{R}^n$ par :

$$d(x, y) = \|x - y\|.$$

Une suite infinie de vecteurs de $\mathbb{R}^n : x^1, x^2, \dots, x^k, \dots$ sera notée $\{x^k\}_{k \in \mathbb{N}}$ ou simplement $\{x^k\}$.

- On dit que la suite $\{x^k\}$ **converge** vers x si la norme $\|x^k - x\|$ tend vers 0 quand $k \rightarrow \infty$ ou, d'une façon équivalente, si :

$$\forall \varepsilon > 0, \exists N : \forall k \geq N \implies \|x^k - x\| < \varepsilon.$$

Soit $S \subset \mathbb{R}^n$ un sous-ensemble de \mathbb{R}^n .

- S est dit **fermé** si toute suite convergente d'éléments de S a une limite dans S :

$$\left. \begin{array}{l} \{x^k\} \subset S \\ x^k \longrightarrow x \end{array} \right\} \Rightarrow x \in S.$$

- S est dit **borné** si toute suite d'éléments de S est une suite bornée ou, d'une façon équivalente, si S est contenu dans une boule B_M de rayon $M < +\infty$

$$B_M = \{x \in \mathbb{R}^n \mid \|x\| < M\}.$$

- Un ensemble $K \subset \mathbb{R}^n$ est dit **compact** si, de toute suite infinie $\{x^k\}_{k \in \mathbb{N}}$ d'éléments de K , on peut en extraire une sous-suite $\{x^\ell\}_{\ell \in L}$ ($L \subset \mathbb{N}$) convergeant vers un élément de K .

- Une propriété équivalente dans \mathbb{R}^n est qu'un sous-ensemble $K \subset \mathbb{R}^n$ est **compact**, si et seulement si il est **fermé et borné**.

- Un sous-ensembles S de \mathbb{R}^n est dit **ouvert** si, pour tout $x_0 \in S$, il existe un voisinage $V_\varepsilon(x_0)$ de x_0 tel que $V_\varepsilon(x_0) \subset S$.

Exemple 2.1 :

- La boule unité $\{x \in \mathbb{R}^n \mid \|x\| < 1\}$ est un ouvert.
- L'ensemble $K = \{x \in \mathbb{R}^2 \mid 2x_1^2 + x_2^2 \leq 4\}$ est un compact.

Maintenant, nous allons énoncer un résultat fondamental concernant l'**existence** d'une solution optimale pour un problème d'optimisation.

Théorème 2.1

Théorème de Weierstrass

Si f est une **fonction réelle continue sur un compact** $K \subset \mathbb{R}^n$ (i.e. K est fermé borné), alors le problème d'optimisation :

$$\begin{cases} \text{Minimiser } f(x) \\ x \in K \end{cases}$$

a une **solution optimale** $x^* \in K$.

Preuve :

- Soit $m = \inf_{x \in K} \{f(x)\}$, donc pour tout $x \in K$ on a : $m \leq f(x)$. (Notons que m peut valoir $-\infty$ si l'ensemble $f(K)$ n'est pas minoré).
On peut alors construire une suite $\{x_k\}$ d'éléments de K telle que $f(x_k) \rightarrow m$.
- Sachant que K est compact, il existe une sous-suite infinie $\{x_\ell\}_{\ell \in L}$ ($L \subset \mathbb{N}$) convergente vers $x^* \in K$.
- Comme f est continue, on a alors : $f(x_\ell) \rightarrow f(x^*)$ et

$$m = \lim_{k \rightarrow \infty} f(x_k) = \lim_{\ell \rightarrow \infty} f(x_\ell) = f(x^*)$$

Comme $f(x^*) > -\infty$, on a $m > -\infty$ et pour tout $x \in K$: $f(x^*) = m \leq f(x)$; donc $x^* \in K$ est une solution optimale du problème posé. \square

- Ce résultat reste valide si on suppose f **semi-continue inférieurement** (s.c.i.).
- Par définition, $f : \mathbb{R}^n \mapsto \mathbb{R}$ est dite semi-continue inférieurement en $\bar{x} \in \mathbb{R}^n$ si et seulement si, pour toute suite convergente $\{x_k\}_{k \in \mathbb{N}}$ de limite \bar{x} , on a :

$$\liminf_{k \rightarrow \infty} f(x_k) \geq f(\bar{x})$$

- $f : \mathbb{R}^n \mapsto \mathbb{R}$ est s.c.i. si et seulement si elle est s.c.i. en tout point de \mathbb{R}^n .

Le corollaire suivant du théorème de Weierstraass est immédiat mais est souvent utile dans les applications, par exemple dans le cas de l'optimisation sans contraintes où l'on cherche un optimum sur \mathbb{R}^n tout entier.

Corollaire 2.1

Soit f une **fonction réelle continue** sur \mathbb{R}^n vérifiant de plus la condition :

$$f(x) \rightarrow +\infty \text{ lorsque } \|x\| \rightarrow +\infty.$$

Alors le problème

$$\begin{cases} \text{Minimiser } f(x) \\ x \in \mathbb{R}^n \end{cases}$$

a une **solution optimale** x^* .

Preuve :

- Soit $x^\circ \in \mathbb{R}^n$ quelconque. En raison de l'hypothèse de croissance à l'infini, il existe $M > 0$ tel que :

$$\text{tout } x \in \mathbb{R}^n \text{ tel que } \|x\| > M \Rightarrow f(x) > f(x^\circ).$$

- Ainsi, le problème se ramène à un problème d'optimisation sur la boule fermée :

$$\{x \in \mathbb{R}^n \mid \|x\| \leq M\},$$

qui est compacte, et le théorème de Weierstrass s'applique. □

Remarque sur la notation min : L'emploi de la notation

$$\min_{x \in S} f(x)$$

sera réservée à des fonctions f telles que, si

$$-\infty < \inf_{x \in S} f(x) < +\infty,$$

alors il existe $x^* \in S$ tel que $f(x^*) = \inf_{x \in S} f(x)$. On pose alors :

$$\min_{x \in S} f(x) = f(x^*).$$

Exemple 2.2 : Soit la fonction $f(x_1, x_2)$ définie par

$$f(x_1, x_2) = x_1^2 + x_2^2 - 1.$$

Pour tout $(x_1, x_2) \in \mathbb{R}^2$, on a $f(x_1, x_2) \geq -1$ et $f(0, 0) = -1$; alors

$$\min_{x \in \mathbb{R}^2} f(x) = -1 = f(0).$$

2.2 Éléments de calcul différentiel

Soit $U \subset \mathbb{R}^n$ un ouvert et $x = \begin{pmatrix} x_1 \\ x_2 \\ \vdots \\ x_n \end{pmatrix} \in U$ fixe. Soit $f : U \rightarrow \mathbb{R}$ une fonction.

- La fonction définie par $f_i : y \mapsto f(x_1, \dots, x_{i-1}, y, x_{i+1}, \dots, x_n)$, est appelée la $i^{\text{ème}}$ **fonction partielle** de f en x .

- La dérivée de f_i en x_i est appelée la **dérivée partielle (première)** par rapport à la $i^{\text{ème}}$ composante de f en x et notée $\frac{\partial f}{\partial x_i}(x)$.

Exemple 2.3 : Soit l'ouvert $U = \mathbb{R}^2 - \{(0, 0)\}$ et la fonction $f(x, y) = \frac{x^2 y^3}{x^2 + y^2}$.

- La dérivée partielle par rapport à x est :

$$\begin{aligned}\frac{\partial f}{\partial x}(x, y) &= \frac{2xy^3(x^2 + y^2) - x^2y^3 \cdot 2x}{(x^2 + y^2)^2} \\ &= \frac{2xy^5}{(x^2 + y^2)^2}\end{aligned}$$

- La dérivée partielle par rapport à y est :

$$\begin{aligned}\frac{\partial f}{\partial y}(x, y) &= \frac{3x^2y^2(x^2 + y^2) - x^2y^3 \cdot 2y}{(x^2 + y^2)^2} \\ &= \frac{3x^4y^2 + x^2y^4}{(x^2 + y^2)^2} = \frac{x^2y^2(3x^2 + y^2)}{(x^2 + y^2)^2}\end{aligned}$$

- Un point $x \in U$ en lequel $\frac{\partial f}{\partial x_i}(x) = 0$ pour tout $i \in \{1, 2, \dots, n\}$ est appelé **point critique** ou **point stationnaire** de f .

- $\frac{\partial f}{\partial x_i}$ est également appelée **dérivée partielle (première)** de f par rapport à x_i .

- Si toutes les dérivées partielles premières de f en un point x existent, on appellera le **gradient** de f au point x le vecteur de \mathbb{R}^n :

$$\nabla f(x) = \begin{pmatrix} \frac{\partial f}{\partial x_1}(x) \\ \frac{\partial f}{\partial x_2}(x) \\ \vdots \\ \frac{\partial f}{\partial x_n}(x) \end{pmatrix}$$

- On définit de la même manière les **dérivées partielles secondes** de f (et d'une façon générale les dérivées partielles d'ordre m de f où $m \in \mathbb{N}$).

Exemple 2.4 : Par exemple, $\frac{\partial^2 f}{\partial x_i \partial x_j}(x)$ signifie la dérivée de premier ordre de $\frac{\partial f}{\partial x_i}(x)$ par rapport à x_j au point x .

- Une fonction f , telle que **toutes ses dérivées partielles d'ordre m existent et sont continues**, est dite de **classe m** et sera notée par $f \in C^m$.

Définition 2.1

Soit u un vecteur de \mathbb{R}^n . On appelle **dérivée directionnelle** de f au point x dans la direction u , la quantité suivante (quand elle existe)

$$f'(x; u) = \lim_{t \rightarrow 0} \frac{f(x + tu) - f(x)}{t}.$$

Note :

- La dérivée partielle de f au point x par rapport à x_i , peut être définie de manière équivalente par la dérivée directionnelle de f au point x dans la direction

$$e_i = (0, \dots, 0, 1, 0, \dots, 0)$$

$\uparrow_{i^{\text{ième}} \text{composante}}$

- Si le gradient de f existe au point x , alors on a

$$f'(x; u) = \nabla f(x)^\top u$$

où $\nabla f(x)^\top = \left(\frac{\partial f}{\partial x_1}(x), \frac{\partial f}{\partial x_2}(x), \dots, \frac{\partial f}{\partial x_n}(x) \right)$.

- Si f est de classe C^2 , on définit le **Hessien** (ou la **matrice Hessienne**) de f en x par la matrice d'ordre n notée $H(x)$ et définie par

$$H(x) = \left[\frac{\partial^2 f}{\partial x_i \partial x_j}(x) \right]_{1 \leq i, j \leq n} = \begin{bmatrix} \frac{\partial^2 f}{\partial x_1^2}(x) & \frac{\partial^2 f}{\partial x_1 \partial x_2}(x) & \cdots & \frac{\partial^2 f}{\partial x_1 \partial x_n}(x) \\ \frac{\partial^2 f}{\partial x_2 \partial x_1}(x) & \frac{\partial^2 f}{\partial x_2^2}(x) & \cdots & \frac{\partial^2 f}{\partial x_2 \partial x_n}(x) \\ \vdots & \vdots & \ddots & \vdots \\ \frac{\partial^2 f}{\partial x_n \partial x_1}(x) & \frac{\partial^2 f}{\partial x_n \partial x_2}(x) & \cdots & \frac{\partial^2 f}{\partial x_n^2}(x) \end{bmatrix}$$

$H(x)$ est une matrice symétrique appelée aussi **matrice jacobienne** associée à f .

Exemple 2.5 :

- Soit la fonction $f(x) = \frac{1}{2}(x_1^2 + x_2^2 + \cdots + x_n^2)$. Son gradient et son Hessien sont

$$\nabla f(x) = \begin{pmatrix} x_1 \\ x_2 \\ \vdots \\ x_n \end{pmatrix} \quad \text{et} \quad H(x) = \begin{pmatrix} 1 & 0 & 0 & \cdots & 0 \\ 0 & 1 & 0 & \cdots & 0 \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & 0 & \cdots & 1 \end{pmatrix} = I$$

où I est la **matrice identité d'ordre n** .

- Soit $f(x) = \frac{1}{2}x^\top Ax + b^\top x$ où A est une matrice symétrique d'ordre n et b un

vecteur de \mathbb{R}^n . x^\top signifie le transposé du vecteur x , i.e.

$$x = \begin{pmatrix} x_1 \\ x_2 \\ \vdots \\ x_n \end{pmatrix}, \quad x^\top = (x_1, x_2, \dots, x_n).$$

On a le gradient et le Hessien

$$\nabla f(x) = Ax + b, \quad H(x) = A.$$

Le premier point rentre dans le cadre du deuxième. En effet ;

$$f(x) = \frac{1}{2} (x_1^2 + x_2^2 + \dots + x_n^2) = \frac{1}{2} x^\top I x.$$

2.3 Développement de Taylor et formule de la moyenne.

- Si f est de classe C^1 dans une région contenant le segment $[x, y]$, alors le développement de Taylor à l'ordre 1 s'écrit :

$$f(y) = f(x) + \nabla f(x)^\top (y - x) + o(\|y - x\|),$$

où $o(\|y - x\|) = \|y - x\| \varepsilon(y - x)$ avec $\varepsilon : \mathbb{R}^n \rightarrow \mathbb{R}$ telle que

$$\varepsilon(y - x) \rightarrow 0, \text{ lorsque } \|y - x\| \rightarrow 0.$$

- Et la formule de la moyenne d'ordre 1 est : il existe α , $0 < \alpha < 1$ tel que

$$\begin{cases} f(y) = f(x) + \nabla f(\xi)^\top (y - x) \\ \xi = \alpha x + (1 - \alpha)y \end{cases}$$

- Si de plus f est de classe C^2 , alors le développement de Taylor à l'ordre 2 s'écrit :

$$f(y) = f(x) + \nabla f(x)^\top (y - x) + \frac{1}{2} (y - x)^\top H(x) (y - x) + o(\|y - x\|^2).$$

- Et la formule de la moyenne d'ordre 2 est : il existe α , $0 < \alpha < 1$ tel que

$$\begin{cases} f(y) = f(x) + \nabla f(x)^\top (y - x) + \frac{1}{2} (y - x)^\top H(\xi) (y - x) \\ \xi = \alpha x + (1 - \alpha)y \end{cases}$$

Remarque sur les notations :

- Soient a et b deux points de \mathbb{R}^n . On désigne par le segment $[a, b]$ l'ensemble des points $x = ta + (1 - t)b$ où $t \in [0, 1]$

$$[a, b] = \{x = ta + (1 - t)b, \text{ tel que } t \in [0, 1]\}$$

- Soient $x \in \mathbb{R}^n$ et $y \in \mathbb{R}^n$, on note par :

$$x^\top y = \sum_{i=1}^n x_i y_i$$

qui n'est autre que le produit scalaire euclidien. Parfois ce produit scalaire sera noté tout simplement par (x, y) .

3 Rappels sur les matrices définies positives

Soit $A = (a_{ij})_{1 \leq i, j \leq n}$ une matrice d'ordre n **symétrique** (i.e, $a_{ij} = a_{ji}, 1 \leq i, j \leq n$).

- A est dite **définie positive** si

$$x^\top A x > 0, \forall x \neq 0 \text{ et } x \in \mathbb{R}^n.$$

On dit aussi la forme quadratique $x^\top A x$ est définie positive.

- A est dite **semi-définie positive** si

$$x^\top A x \geq 0, \forall x \in \mathbb{R}^n.$$

Le résultat suivant permet de donner une caractérisation des matrices symétriques définies positives.

Théorème 3.1

Une matrice A symétrique est **définie positive** si et seulement si **tous les mineurs principaux successifs** de la matrice A sont **strictement positifs**.

Note :

- Les mineurs principaux successifs sont les déterminants des sous matrices carrées obtenues en éliminant successivement la dernière ligne et la dernière colonne.

- Pour une matrice $n \times n$, il y a n mineurs principaux.

Exemple 3.1 :

- Par exemple, si on considère la matrice suivante

$$A = \begin{bmatrix} a_{11} & a_{12} & a_{13} \\ a_{21} & a_{22} & a_{23} \\ a_{31} & a_{32} & a_{33} \end{bmatrix}$$

- alors les trois mineurs principaux sont les trois déterminants

$$a_{11}, \quad \begin{vmatrix} a_{11} & a_{12} \\ a_{21} & a_{22} \end{vmatrix}, \quad \begin{vmatrix} a_{11} & a_{12} & a_{13} \\ a_{21} & a_{22} & a_{23} \\ a_{31} & a_{32} & a_{33} \end{vmatrix}$$

Note : Nous ne pouvons pas affirmer ou non qu'une matrice est semi-définie positive pour le fait que les mineurs principaux sont positifs ou nuls !

Exemple 3.2 :

- Soit la matrice A donnée par

$$A = \begin{bmatrix} 2 & 1 & 2 \\ 1 & 3 & 0 \\ 2 & 0 & 5 \end{bmatrix}$$

Alors, on a ses mineurs principaux

$$a_{11} = 2, \quad \begin{vmatrix} 2 & 1 \\ 1 & 3 \end{vmatrix} = 5, \quad \begin{vmatrix} 2 & 1 & 2 \\ 1 & 3 & 0 \\ 2 & 0 & 5 \end{vmatrix} = 2 \begin{vmatrix} 1 & 2 \\ 3 & 0 \end{vmatrix} + 5 \begin{vmatrix} 2 & 1 \\ 1 & 3 \end{vmatrix} = -12 + 25 = 13$$

Puisque tous les mineurs principaux sont strictement positifs, A est définie positive.

- Soit une autre matrice A donnée par

$$A = \begin{bmatrix} 0 & 0 & 1 \\ 0 & -1 & -1 \\ 1 & -1 & 1 \end{bmatrix}$$

On a

$$a_{11} = 0, \quad \begin{vmatrix} 0 & 0 \\ 0 & -1 \end{vmatrix} = 0, \quad \begin{vmatrix} 0 & 0 & 1 \\ 0 & -1 & -1 \\ 1 & -1 & 1 \end{vmatrix} = \begin{vmatrix} 0 & 1 \\ -1 & -1 \end{vmatrix} = 1.$$

Tous les mineurs principaux de A sont positifs ou nuls, et pourtant la matrice A n'est pas semi-définie positive. En effet, calculons $x^\top Ax$

$$\begin{aligned} (x, y, z) \begin{bmatrix} 0 & 0 & 1 \\ 0 & -1 & -1 \\ 1 & -1 & 1 \end{bmatrix} \begin{pmatrix} x \\ y \\ z \end{pmatrix} &= (x, y, z) \begin{pmatrix} z \\ -y - z \\ x - y + z \end{pmatrix} \\ &= 2xz - 2yz - y^2 + z^2 \end{aligned}$$

Ainsi en prenant $(x, y, z) = (0, 1, 0)$, on observe que $(0, 1, 0)A \begin{pmatrix} 0 \\ 1 \\ 0 \end{pmatrix} = -1 < 0$.

Note : Soit A une matrice symétrique. Alors on a les résultats suivants :

- A est **définie positive** si et seulement si **toutes les valeurs propres** de A sont **strictement positives**.
- A est **semi-définie positive** si et seulement si **toutes les valeurs propres** de A sont **positives ou nulles**.

4 Ensembles et fonctions convexes

Dans les problèmes d'optimisation, avec ou sans contraintes, une notion va jouer un rôle très important : celle de **convexité** [3].

4.1 Ensembles convexes

Définition 4.1

- Un ensemble $S \subset \mathbb{R}^n$ est dit **convexe** si et seulement si :

$$\left. \begin{array}{l} \forall x \in S \\ \forall y \in S \\ \forall \lambda \in [0, 1] \end{array} \right\} \Rightarrow \lambda x + (1 - \lambda)y \in S.$$

- C'est équivalent à dire que :

$$\left. \begin{array}{l} \forall x \in S \\ \forall y \in S \end{array} \right\} \Rightarrow \text{le segment } [x, y] \subset S.$$




FIGURE 1.2 – Convexité d'un ensemble.

Exemple 4.1 : Soit $a = \begin{pmatrix} a_1 \\ a_2 \\ \vdots \\ a_n \end{pmatrix}$ un vecteur non nul de \mathbb{R}^n et soit c un nombre réel. On appelle **hyperplan** l'ensemble $H = \{x \in \mathbb{R}^n, a^\top x = c\}$.

Note : Un hyperplan est convexe.

4.2 Fonctions convexes

Définition 4.2

Soit $S \subset \mathbb{R}^n$ un ensemble convexe. On dit que :


- 1 $f : S \rightarrow \mathbb{R}$ est **convexe**, si elle vérifie pour tout $x, y \in S$ et tout $\lambda \in [0, 1]$

$$f(\lambda x + (1 - \lambda)y) \leq \lambda f(x) + (1 - \lambda)f(y)$$


- 2 f est dite **strictement convexe**, si elle vérifie pour tout $x, y \in S$ et tout $\lambda \in]0, 1[$

$$f(\lambda x + (1 - \lambda)y) < \lambda f(x) + (1 - \lambda)f(y)$$

Géométriquement, une fonction est convexe si le segment joignant deux points du graphe se situe au dessus de celui-ci.

**Exemple 4.2 :**

- La fonction $f(x) = [x]_+^2$ est convexe, où par définition $[x]_+ = \begin{cases} x, & \text{si } x > 0 \\ 0, & \text{sinon} \end{cases}$.



- Alors que les fonctions $g(x) = e^x$ et $h(x) = x^2$, sont strictement convexes.

Propriété 4.1

- La somme de deux fonctions convexes est convexe.
- Le produit d'une fonction convexe par un scalaire positif est convexe.

Théorème 4.1

Soit $f : S \rightarrow \mathbb{R}$ une fonction de classe C^1 , où S est un ensemble convexe. La fonction f est convexe si et seulement si $\forall x, y \in S, f(y) \geq f(x) + \nabla f(x)^\top (y - x)$.

Preuve :

- Condition nécessaire :

✓ Supposons que f est convexe. Alors $\forall \alpha \in [0, 1]$,

$$\begin{aligned} f(\alpha y + (1 - \alpha)x) &\leq \alpha f(y) + (1 - \alpha)f(x) \\ \frac{f(x + \alpha(y - x)) - f(x)}{\alpha} &\leq f(y) - f(x), \quad \forall \alpha \in]0, 1]. \end{aligned}$$

✓ En passant à la limite vers 0 en α , on obtient

$$\nabla f(x)^\top (y - x) \leq f(y) - f(x)$$

• **Condition suffisante :**

✓ Supposons que $f(y) \geq f(x) + \nabla f(x)^\top (y - x)$, $\forall x, y \in S$. Fixons $x_1, x_2 \in S$ (mais quelconques) et $\alpha \in [0, 1]$. Posons

$$x = \alpha x_1 + (1 - \alpha)x_2 \in S \quad (\text{car } S \text{ est convexe}), \text{ et } y = x_1.$$

Alors, on a :

$$f(x_1) \geq f(x) + \nabla f(x)^\top (x_1 - x) \quad (1.4)$$

✓ Puis fixons $y = x_2$. Alors, on a :

$$f(x_2) \geq f(x) + \nabla f(x)^\top (x_2 - x) \quad (1.5)$$

✓ Multiplions (1.4) par α et (1.5) par $(1 - \alpha)$ et ajoutons ces termes membre à membre, on obtient

$$\alpha f(x_1) + (1 - \alpha)f(x_2) \geq f(x) + \nabla f(x)^\top \underbrace{(\alpha x_1 + (1 - \alpha)x_2 - x)}_{=0}$$

$$\text{donc } f(\alpha x_1 + (1 - \alpha)x_2) \leq \alpha f(x_1) + (1 - \alpha)f(x_2). \quad \square$$

Exemple 4.3 :

• Soit la fonction $f(x) = a_0 + a_1x_1 + \dots + a_nx_n = a_0 + a^\top x$. Alors, on a

$$\nabla f(x) = (a_1, a_2, \dots, a_n)^\top = a.$$

D'autre part, on a

$$f(y) - f(x) = a^\top (y - x) \quad \text{et} \quad \nabla f(x)^\top (y - x) = a^\top (y - x).$$

On peut donc noter l'égalité $f(y) - f(x) = \nabla f(x)^\top (y - x)$, et en déduire donc que f est convexe.

• Soit la fonction $f(x_1, x_2) = |x_1|$. Cette fonction n'est pas de classe C^1 mais elle est convexe. En effet, pour $x = (x_1, x_2)$ et $y = (y_1, y_2)$ on a

$$\begin{aligned} f(\alpha x + (1 - \alpha)y) &= f(\alpha x_1 + (1 - \alpha)y_1, \alpha x_2 + (1 - \alpha)y_2) \\ &= |\alpha x_1 + (1 - \alpha)y_1| \\ &\leq \alpha |x_1| + (1 - \alpha) |y_1| \end{aligned}$$

$$\text{donc } f(\alpha x + (1 - \alpha)y) \leq \alpha f(x) + (1 - \alpha)f(y).$$

Théorème 4.2

Soit $f : S \rightarrow \mathbb{R}$ une fonction de classe C^2 . Alors f est convexe si et seulement si pour tout $x \in S$, la matrice Hessienne $H(x)$ est semi-définie positive.

Preuve :

• Condition nécessaire :

- ✓ Soit $x \in S$ et soit $z \in \mathbb{R}^n$. Il existe un $t \in \mathbb{R}$ (suffisamment petit) tel que $x + tz \in S$.
- ✓ D'après la formule de Taylor, on a :

$$f(x + tz) = f(x) + t \nabla f(x)^\top z + \frac{1}{2} t^2 z^\top H(\xi) z,$$

où $\xi = \alpha x + (1 - \alpha)(x + tz)$, avec $\alpha \in]0, 1[$.

- ✓ Comme f est convexe, alors

$$\begin{aligned} f(x + tz) &= f(x) + t \nabla f(x)^\top z + \frac{1}{2} t^2 z^\top H(\xi) z \\ &\geq f(x) + t \nabla f(x)^\top z \end{aligned}$$

$$\text{i.e., } \frac{1}{2} t^2 z^\top H(\xi) z \geq 0 \Rightarrow z^\top H(\xi) z \geq 0$$

Lorsque $t \rightarrow 0$, on a $\xi \rightarrow x$ et $H(\xi) \rightarrow H(x)$, car $H \in C^0$ (puisque $f \in C^2$).
D'où $z^\top H(x) z \geq 0$ et c'est vrai pour tout $z \in \mathbb{R}^n$.

• Condition suffisante :

- ✓ D'après la formule de Taylor, on a pour tout $x, y \in S$:

$$f(y) = f(x) + \nabla f(x)^\top (y - x) + \frac{1}{2} (y - x)^\top H(\xi) (y - x)$$

avec $\xi \in [x, y] \subset S$ (car S est convexe).

- ✓ Or par hypothèse on a : $(y - x)^\top H(\xi) (y - x) \geq 0$ d'où,

$$f(y) \geq f(x) + \nabla f(x)^\top (y - x),$$

ce qui entraîne (d'après le Théorème 4.1) que f est convexe. □

Théorème 4.3

Si $f : S \rightarrow \mathbb{R}$ est de classe C^2 et si la matrice Hessienne $H(x)$ en tout point x de S est définie positive alors f est strictement convexe.

Preuve :

- La formule de Taylor donne :

$$f(y) = f(x) + \nabla f(x)^\top (y - x) + \frac{1}{2}(y - x)^\top H(\xi)(y - x)$$

où $x, y \in S$ et $\xi \in [x, y] \subset S$ (S convexe).

- Comme $H(z)$ est définie positive pour tout $z \in S$ alors

$$\frac{1}{2}(y - x)^\top H(\xi)(y - x) > 0, y \neq x, \text{ d'où } f(y) > f(x) + \nabla f(x)^\top (y - x), \forall x, y \in S.$$

- Fixons, $x_1, x_2 \in S, x_1 \neq x_2$ (quelconques) et soit $\lambda \in]0, 1[$. Posons $x = \lambda x_1 + (1 - \lambda)x_2 \in S$ et $y = x_1$, on a :

$$f(x_1) > f(x) + \nabla f(x)^\top (x_1 - x) \quad (1.6)$$

De même en posant $y = x_2$, on obtient

$$f(x_2) > f(x) + \nabla f(x)^\top (x_2 - x) \quad (1.7)$$

- Multiplions (1.6) par λ et (1.7) par $(1 - \lambda)$ et ajoutons terme à terme, on obtient

$$\lambda f(x_1) + (1 - \lambda)f(x_2) > f(x) + \nabla f(x)^\top (\underbrace{\lambda x_1 + (1 - \lambda)x_2 - x}_{=0})$$

$$\text{d'où } f(\lambda x_1 + (1 - \lambda)x_2) < \lambda f(x_1) + (1 - \lambda)f(x_2),$$

pour tous $x_1, x_2 \in S, x_1 \neq x_2$ et pour tout $\lambda \in]0, 1[$. □

Note : Dans le théorème précédent, la condition sur la matrice Hessienne est une condition suffisante **mais pas nécessaire**.

Les notions d'ensemble convexe et de fonction convexe sont reliées par ce résultat :

Théorème 4.4

Soit $C \subset \mathbb{R}^n$ un **convexe** et $f : C \rightarrow \mathbb{R}$ une **fonction convexe**. Alors pour tout M fini l'ensemble $S_M = \{x \in C, f(x) \leq M\}$ est **convexe**.

Preuve :

- Soit $x, y \in S_M$, donc on a $x, y \in C$ (par définition de S_M) et comme C est convexe alors $\alpha x + (1 - \alpha)y \in C$, pour tout $\alpha \in [0, 1]$.
- Comme f est convexe, alors

$$\begin{aligned} f(\alpha x + (1 - \alpha)y) &\leq \alpha f(x) + (1 - \alpha)f(y) \\ &\leq \alpha M + (1 - \alpha)M = M \end{aligned}$$

c'est-à-dire que $\alpha x + (1 - \alpha)y \in S_M$. □

Exemple 4.4 : Soit la fonction convexe $f(x, y) = |x| + y^2$; l'ensemble

$$S_2 = \{(x, y) \in \mathbb{R}^2, f(x, y) \leq 2\}$$

est alors convexe.

Le résultat suivant montre que la notion de solution locale et globale est identique dans le cas des programmes convexes.

Théorème 4.5

Pour un programme convexe de la forme

$$\begin{cases} \text{Minimiser } f(x) \\ x \in S \end{cases}$$

où S est un convexe de \mathbb{R}^n et $f : S \rightarrow \mathbb{R}$ est une fonction convexe, tout optimum local est aussi optimum global.

Preuve :

- Soit x^* un optimum local. Pour montrer que x^* est un optimum global, considérons $y \in S$, $y \neq x^*$ quelconque et montrons que nécessairement $f(x^*) \leq f(y)$.
- Raisonnons par l'absurde, en supposant qu'il existe au moins un $y \in S$ ($y \neq x^*$) tel que $f(x^*) > f(y)$.
- Comme f est convexe et que S est convexe alors pour tout $\alpha \in]0, 1]$, on a :

$$\begin{aligned} f(x^* + \alpha(y - x^*)) &= f(\alpha y + (1 - \alpha)x^*) \\ &\leq \alpha f(y) + (1 - \alpha)f(x^*) \\ &< f(x^*), \quad \text{car } \alpha(f(y) - f(x^*)) < 0, \forall \alpha \in]0, 1]. \end{aligned}$$

D'où la contradiction car x^* est un optimum local (il suffit de prendre α assez petit). □

Note : La démonstration du théorème précédant en y introduisant les contraintes $g_i(x) \leq 0$, $i = 1, \dots, m$ est la même à condition que toutes les fonctions g_i soient convexes.

Bibliographie :

- [1] V. Karmanov. Programmation mathématique. Editions Mir, Moscou, 1977.
- [2] M. Minoux. Programmation mathématique. Théorie et algorithmes. Lavoisier, Paris, 2008.
- [3] B. T. Polyak. Introduction to Optimization. Optimization Software, New York, 1987.